



GEOSTATISTIQUES

Interpolation spatiale par krigeage ordinaire

RESUME

Etude de la prévision des températures moyennes en France métropolitaine pour la fin du XXIème siècle

A l'attention de Monsieur Julien CAUDEVILLE, chercheur et enseignant.

Guillaume CHEVRON

chevron.guillaume@gmail.com
+33 6 76 77 34 26

Le 15 septembre 2022.

le cnam

Table des matières

| | |
|--|----|
| I. Vers une hausse des températures moyennes du fait du réchauffement climatique | 2 |
| A. Les conséquences d'une hausse des températures moyennes | 2 |
| B. Le problème des boucles de rétroaction positive..... | 2 |
| C. Prédire le climat de demain grâce aux scénarios RCP du GIEC..... | 2 |
| D. Le scénario RCP4.5 comme objet d'étude | 3 |
| II. Exploration des données de températures moyennes | 4 |
| A. Définition et cadrage de la donnée à analyser | 4 |
| B. Statistiques descriptives & analyse de la distribution | 5 |
| C. Saisonnalité & variabilité..... | 6 |
| D. Analyse de l'autocorrélation spatiale..... | 7 |
| III. Analyse variographique de la température | 8 |
| A. Choix de la méthode d'estimation linéaire | 8 |
| B. Calcul et ajustement de la fonction aléatoire intrinsèque..... | 8 |
| C. Analyse visuelle des diagrammes associés aux variogrammes expérimentaux | 9 |
| D. Création d'une grille de projection | 11 |
| E. Estimation des prévisions par krigeage ordinaire..... | 11 |
| F. Comparaison annuelle des températures moyennes | 12 |
| IV. Etude complémentaire de la température moyenne entre 2021 et 2022 | 13 |

I. Vers une hausse des températures moyennes du fait du réchauffement climatique

A. Les conséquences d'une hausse des températures moyennes

Le 29 août 2022, le Système européen d'information sur les feux de forêts (EFFIS) enregistrait un peu plus de 62 000 hectares de végétation brûlés en France métropolitaine, représentant ainsi un record jamais atteint depuis la création de ce système de mesure en 2006¹. Ce triste record s'approche des chiffres de 1976 et 2003, années considérées comme hors normes avec des feux de forêt ayant parcouru 88.000 et 73.000 hectares.




Figure 1 – Evolution du nombre d'incendies et d'hectares de végétation brûlés en France métropolitaine

B. Le problème des boucles de rétroaction positive

Bien que la grande majorité des feux de forêts soit d'origine humaine, volontaire ou accidentelle, la recherche scientifique s'accorde à dire que leur intensité et leur ampleur sont largement aggravées par les conséquences du réchauffement climatique. La multiplication de ces incendies, accentuée par la sécheresse et par la hausse de la température moyenne globale, entraîne un mécanisme de boucle de rétroaction positive². Ce phénomène de boucle s'explique comme suit : la hausse de la température moyenne globale entraîne une hausse de la fréquence et de la gravité des incendies. En brûlant, la végétation victime de ces incendies libère une quantité supplémentaire de CO², qui a son tour accroît la fréquence du nombre d'incendie et ainsi accélère la massification des émissions de gaz à effet de serre. Cette boucle, appelée boucle de rétroaction incendie-climat, n'est pas la seule menace puisqu'il existe d'autres boucles de rétroaction positive comme la fonte du permafrost, entraînant des émissions records de méthane, ou encore la libération importante de vapeur d'eau dans l'atmosphère, pouvant potentiellement doubler le réchauffement par rapport à l'effet direct du CO².

Il est donc essentiel de s'intéresser de plus près à la hausse de la température moyenne, étant donné qu'il s'agit d'une des causes principales de cette boucle incendie-climat. En prévoir les grandes tendances demain, ainsi que les ordres de grandeur associés, permet de mieux diriger l'action climatique dès aujourd'hui.

C. Prédire le climat de demain grâce aux scénarios RCP du GIEC

A ce titre, le cinquième rapport d'évaluation du GIEC³ paru en 2014 (AR5) tente de modéliser les prévisions de température moyenne en 2100 sur la base de quatre scénarios distincts concernant la quantité de gaz à effet de serre qui sera émise entre 2000 et 2100. Chaque scénario, appelé scénario RCP⁴, donne une variante jugée probable du climat qui résultera du niveau d'émission choisi comme hypothèse de travail.




Figure 2 – Représentation des eq-CO₂ du forçage atmosphérique

¹ D'après l'article de francebleu.fr, écrit par la journaliste Faustine Mauerhan, paru le 29 août 2022 et accessible depuis le lien suivant : [shorturl.at/bdFMW](https://www.francebleu.fr/infos/meteo/le-record-des-feux-de-for-et-en-france-est-atteint-29-08-2022)

² Pour plus d'information sur le phénomène de boucle rétroaction positive, consultez l'article de Numerama du 23 septembre 2021 accessible depuis le lien suivant : [shorturl.at/osyzO](https://www.numerama.com/fr/article/le-rechauffement-climatique-est-il-en-train-de-s-accroitre-23-09-2021/)

³ Groupe d'experts intergouvernemental sur l'évolution du climat (ou IPCC pour Intergovernmental Panel on Climate Change)

⁴ Representative Concentration Pathway en anglais ou Trajectoires représentatives de concentration en français.

Les quatre scénarios sont nommés d'après la gamme de forçage radiatif⁵ ainsi obtenue pour l'année 2100.

| Scenario | Radiative Forcing | Concentration | Temperature (2046–2065) | Temperature (2081–2100) | Pathway shape |
|----------|-----------------------|---------------------------|-------------------------|-------------------------|---------------------------------|
| RCP8.5 | >8.5 W/m ² | ~1370 CO ₂ -eq | 2.0 (1.4 to 2.6) | 3.7 (2.6 to 4.8) | Rising |
| RCP6.0 | ~6 W/m ² | ~850 CO ₂ -eq | 1.3 (0.8 to 1.8) | 2.2 (1.4 to 3.1) | Stabilization without overshoot |
| RCP4.5 | ~4.5 W/m ² | ~650 CO ₂ -eq | 1.4 (0.9 to 2.0) | 1.8 (1.1 to 2.6) | Stabilization without overshoot |
| RCP2.6 | ~2.6W/m ² | ~490 CO ₂ -eq | 1.0 (0.4 to 1.6) | 1.0 (0.3 to 1.7) | Peak and decline |

Figure 3 – Table résumée des principaux indices pour chaque scénario RCP⁶

Le scénario RCP2.6 est considéré comme le plus optimiste car il demande des mesures de restriction des émissions très rigoureuses d'ici 2050 pour être appliqué. En effet, ce scénario nécessite que les émissions de dioxyde de carbone (CO₂) commencent à décliner à compter de l'année 2020 pour finir par être égales à zéro en 2100. Cela suppose également que les émissions de méthane (CH₄) aient été divisées par deux en 2100 par rapport à 2020, et que les émissions de dioxyde de soufre aient baissé de 10% en 2100 par rapport à 1980-1990. En supposant enfin des émissions négatives de CO₂ à hauteur de deux gigatonnes par an, ce scénario permettrait de maintenir la hausse de température globale en-dessous des 2°C d'ici 2100.

Le scénario RCP4.5 est considéré par le GIEC comme un scénario intermédiaire avec une stabilisation des émissions avant la fin du XXI^e siècle à un niveau faible. A ce titre, il suppose que les émissions de dioxyde de carbone déclinent à compter de 2045 pour atteindre la moitié de leur niveau de 2050 en 2100. En complément, les émissions de méthane devront être réduites de 25% de leur niveau de 2040 en 2050, et les émissions de dioxyde de soufre (CH₄) de 20% par rapport à leur niveau de 1980-1990. Enfin, comme pour le RCP2.6, les émissions négatives sont supposées atteindre deux gigatonnes de CO₂ par an. En conséquence de cela, les estimations de hausse de la température moyenne seraient alors comprises entre 2°C et 3°C d'ici 2100, avec une hausse du niveau des océans 35% plus importante que pour le scénario RCP2.6. Cela impliquerait mécaniquement la disparition de nombreuses espèces végétales et animales qui ne pourront pas s'adapter aux effets climatiques. D'après les experts, ce scénario semble être le plus probable, en particulier car il est fondé sur l'hypothèse d'une disponibilité exagérément accrue des réserves en énergies fossiles et donc de changements tardifs en termes de politiques énergétiques.

Le scénario RCP6.0 estime que les émissions atteindront un pic autour de 2080 pour se stabiliser ensuite avant la fin du XXI^e siècle à un niveau moyen. Ici, l'utilisation tardive de technologies et de stratégies de réduction des gaz à effet de serre permettrait tout de même de maintenir un forçage radiatif stable à l'horizon 2100. Les prévisions de température supposeraient quant à elles la poursuite du réchauffement climatique après 2100 avec une hausse des niveaux de CO₂ atteignant les 670 ppm. Ce scénario impliquerait une hausse de la température moyenne globale entre 3°C et 4°C d'ici 2100.

Le scénario RCP8.5 est le plus pessimiste des quatre puisqu'il part du principe qu'aucune action climatique ne sera entreprise d'ici 2100 et donc que les émissions de gaz à effet de serre continueront d'augmenter au rythme actuel. Ce scénario est donc peu probable bien qu'il puisse servir de catalyseur au changement – voire de signal d'alerte – pour le grand public.

D. Le scénario RCP4.5 comme objet d'étude

En tenant compte des politiques récentes sur le climat, en particulier l'Accord de Paris⁷, le scénario RCP4.5 semble être le plus approprié dans le cadre d'une étude sur les prévisions de température à l'horizon 2100. Toutefois, il est important de rappeler que les estimations actuelles semblent plutôt se diriger vers une hausse de 3°C à 4°C si aucun réel changement en matière de transition énergétique et de comportement de consommation venait à être entrepris.

L'étude menée ici s'intéressera donc à estimer la température moyenne en France métropolitaine pour la période 2071-2100 afin de pouvoir la comparer à la période 2021-2050. Une analyse complémentaire des années 2021 et 2022 pourra également permettre de se faire une idée de possibles tendances futures. Pour ce faire, l'interpolation spatiale des données sera effectuée par krigeage ordinaire afin d'estimer les prévisions de températures à l'horizon le plus éloigné et pour certains mois préalablement identifiés.

⁵ Exprimé en W/m², un forçage radiatif est un changement du bilan radiatif (c'est-à-dire la différence entre le rayonnement entrant et le rayonnement sortant) au sommet de la troposphère (situé entre 10 et 16 km d'altitude), dû à un changement d'un des facteurs d'évolution du climat – comme la concentration des gaz à effet de serre.

⁶ Pour plus d'information, consultez le Summary for Policymakers (archived 16 July 2014), IPCC AR5 WG1 2013, p. 21

⁷ L'objectif à long terme de l'accord de Paris en matière de température est de maintenir l'augmentation de la température moyenne de la planète bien en dessous de 2°C par rapport aux niveaux préindustriels, et de préférence de limiter l'augmentation à 1,5°C, en reconnaissant que cela réduirait considérablement les impacts du changement climatique.

II. Exploration des données de températures moyennes

A. Définition et cadrage de la donnée à analyser

Les données utilisées dans le cadre de cette étude sont mises à disposition par Météo-France, service météorologique et climatique national, et calculées à partir de données corrigées du Centre National de Recherches Météorologiques. Elles sont téléchargeables depuis la plateforme ouverte des données publiques françaises data.gouv⁸ et ont été manipulées, traitées puis analysées entièrement via le langage de programmation R.

Elles comportent les moyennes des différents indices mensuels de températures et de nombre de jours de températures, sur les 8602 points terrestres de la France métropolitaine, sur la période de référence (1976-2005) et pour les quatre scenarios RCP décrits plus tôt (2.6, 4.5, 6.0 et 8.5). Ces indices mensuels sont les suivants :

| Indices | Unit | Definition |
|----------|---------|---|
| NORTAV | Celsius | Intégration de Température moyenne journalière |
| NORTNAV | Celsius | Intégration de Température minimale journalière |
| NORTXAV | Celsius | Intégration de Température maximale journalière |
| NORTRAV | Celsius | Intégration de Amplitude thermique journalière |
| NORTXQ90 | Celsius | Intégration de Extrême chaud de la température maximale journalière |
| NORTXQ10 | Celsius | Intégration de Extrême froid de la température maximale journalière |
| NORTNQ10 | Celsius | Intégration de Extrême froid de la température minimale journalière |
| NORTNQ90 | Celsius | Intégration de Extrême chaud de la température minimale journalière |
| NORTXND | Day | Intégration de Nombre de jours anormalement chauds |
| NORTNND | Day | Intégration de Nombre de jours anormalement froids |
| NORTNHT | Day | Intégration de Nombre de nuits anormalement chaudes |
| NORTXHWD | Day | Intégration de Nombre de jours d'une vague de chaleur |
| NORTNCWD | Day | Intégration de Nombre de jours d'une vague de froid |
| NORTNFD | Day | Intégration de Nombre de jours de gel |
| NORTXFD | Day | Intégration de Nombre de jours sans dégel |
| NORSDD | Day | Intégration de Nombre de journées d'été |
| NORTTR | Day | Intégration de Nombre de nuits tropicales |
| NORHDD | Celsius | Intégration de degré-jours de chauffage |
| NORCDD | Celsius | Intégration de degré-jours de climatisation |

Figure 4 – Liste des indices présent dans le jeu de données étudié

En complément de ces indices, le jeu de données comprend également les coordonnées GPS⁹ des 8602 points terrestres, le numéro du mois associé à la mesure mensuelle, ainsi que le type d'intégration permettant d'identifier l'horizon de prévision. L'horizon le plus proche H1, correspondant à la période 2021-2050, sera utilisé tout au long de l'étude comme référentiel de comparaison à l'horizon le plus éloigné H3 (période 2071-2100). L'horizon à moyen terme, représentant la période 2041-2070, sera quant à lui mis de côté.

L'analyse de l'évolution des indices fournit par ce jeu de données peut offrir de nombreuses applications statistiques pratiques permettant d'aider à mieux comprendre les phénomènes de dérèglement climatique. Toutefois, et par souci de cadrage, le parti pris de cette étude est de centrer l'analyse autour de la donnée d'intégration de la température moyenne journalière en France métropolitaine afin d'en identifier les tendances futures et de déterminer une photographie de l'hexagone à la fin XXIème siècle.

La préparation de l'espace de travail et du prétraitement de la donnée à analyser a été effectuée comme suit :

```
### I. Exploring the data
## A. Preparing workspace before importing the data
# 1/ Setting working directory
setwd('C:/Users/J1038629/OneDrive - TOTAL/9. Personal/CNAM/STA112 - Statistiques Spatiales/2. Datasets')

# 2/ Loading the required packages
packages_required = c('gstat', 'sp', 'ggplot2', 'ape', 'Rcpp', 'raster', 'RGeostats')
installing_packages = function(packages){
  new_packages = packages[!(packages %in% installed.packages()[, 'Package'])]
  if (length(new_packages))
    install.packages(new_packages, dependencies = TRUE)
  sapply(packages, require, character.only = TRUE)
}
installing_packages(packages_required)
```

⁸ Le jeu de données, intitulé « Indices mensuels de température et nombre de jours de température issus du modèle Aladin-Climat » est téléchargeable depuis le lien suivant : shorturl.at/dNPXZ

⁹ Les latitudes et longitudes sont exprimées en degrés décimaux.

L'import de librairies spécifiques est requis afin de pouvoir procéder aux différentes analyses et projections, en particulier 'gstat' et 'RGeostats' qui rendent possible l'interpolation spatiale de données par krigeage.

```
## B. Loading the data set related to temperature according to 4.5 RCP scenario
# 1/ Creating a dataframe from the .txt file
temperature_means_df = read.table('Tempe_RCP4.5_mensuel.txt', sep=';', dec='.',
header=FALSE, skipNul=TRUE, encoding='UTF-8') # Reading the data only without loading the
header
colnames(temperature_means_df) = c('Point', 'Latitude', 'Longitude', 'Contexte',
'Integration', 'Mois', 'NORTAV', 'NORTNAV',
'NORTXAV', 'NORTRAV', 'NORTXQ90', 'NORTXQ10',
'NORTNQ10', 'NORTNQ90', 'NORTXND', 'NORTNND',
'NORTNHT', 'NORTXHWD', 'NORTNCWD', 'NORTNFD',
'NORTXFD', 'NORTSD', 'NORTR', 'NORHDD', 'NORCDD')
temperature_means_df = subset(temperature_means_df, select=c(10:26)) # Keeping only average temperatures among the initial
data set
summary(temperature_means_df$NORTAV) # Checking the distribution of the average temperatures
head(temperature_means_df)
```

Seule l'indice 'NORTAV' a été conservé au sein du jeu de données afin d'alléger la compréhension des sorties obtenues au fur et à mesure de l'étude.

B. Statistiques descriptives & analyse de la distribution

Le résumé de la répartition des valeurs de la donnée NORTAV donne une première indication du type de distribution. Toutefois, il est intéressant d'approfondir cette répartition en visualisant cette distribution afin de se faire une idée du comportement des températures moyennes.

| Min. | 1st Qu. | Median | Mean | 3rd Qu. | Max. |
|-------|---------|--------|-------|---------|-------|
| -8.48 | 7.12 | 11.65 | 12.14 | 17.33 | 28.01 |

La prise en compte de l'horizon peut également apporter des informations préliminaires quant à l'évolution des températures moyennes dans le temps.

```
# 2/ Checking the distribution of NORTAV
# a) Excluding 'horizon'
plot_temperature_means_without_horizon = ggplot(data=df_temperature_means, aes(x=NORTAV, color=NORTAV)) +
geom_density(alpha=0.2, fill="#E69F00") +
theme(legend.position='bottom', text=element_text(family='TT Courier New', size=10)) +
labs(title='Temperature distribution for horizon 3 (2071-2100)', x='Average Temperature', y = 'Frequency')
plot_temperature_means_without_horizon

# b) Including 'horizon'
plot_temperature_means_with_horizon = ggplot(data=df_temperature_means, aes(x=NORTAV, group=Integration, fill=Integration)) +
geom_density(alpha=0.2, fill="#E69F00") +
theme(legend.position='bottom', text=element_text(family='TT Courier New', size=10)) +
labs(title='Temperature distribution per type of horizon', x='Average Temperature', y = 'Frequency')
plot_temperature_means_with_horizon
```

Une rapide analyse de la distribution de la température moyenne permet de donner un premier aperçu des tendances futures et d'opérer de premières hypothèses pour la suite de l'étude.




Figure 5 – Distribution de la température moyenne en France métropolitaine avec et sans horizon

La fréquence importante de températures autour de 17°C pour l'horizon le plus proche, représentant probablement les périodes de printemps et d'été, semble se déporter pour l'horizon le plus lointain aux alentours de 22°C. De la même manière, le pic à 7°C représentant très probablement les périodes d'automne et d'hiver, semble quant à lui se déplacer à 8°C. Ces deux observations feraient donc état d'un réchauffement moyen des températures saisonnières.

C. Saisonnalité & variabilité

L'étude de la saisonnalité pourrait également apporter de l'information vis-à-vis du comportement des températures en fonction des mois observés et des différents horizons.

```
# 3/ Checking seasonality and temperature trend based on mean and standard deviation analysis
temperature_monthly_all = setNames(
  do.call(data.frame,
    aggregate(temperature_means_df$NORTAV ~ temperature_means_df$Mois+temperature_means_df$Integration,
      data=temperature_means_df,
      function(x) c(Mean = mean(x), SD = sd(x)))),
  c('month', 'Horizon', 'temperature_avg', 'temperature_sd'))
plot_temperature_sd_monthly = ggplot(data=temperature_monthly_all,
  aes(x=as.factor(month),
    y=temperature_sd,
    group=Horizon,
    color=Horizon)) + geom_line() + geom_point() +
  theme(legend.position='bottom', text=element_text(family='LM Roman 10', size=10)) +
  labs(title='Temperature variability per month', x='Month', y='Standard Deviation')
plot_temperature_sd_monthly
```

En particulier, l'évolution de l'écart-type des températures mensuelles permet de se faire une idée de la variabilité des valeurs observées. Cette information pourra être utile par la suite dans l'étude de l'autocorrélation.

La variance est la plus forte pour les mois de février, août et décembre où trois pics respectifs sont observables. Cela est sans doute en partie dû à la complexité du territoire français en métropole, riche d'une diversité des milieux (montagneux, littoraux, etc.) et de contrastes naturels importants (altitude, climats, végétation, etc.).

Par ailleurs, la variabilité des températures en février semble substantiellement baisser dans le temps. A l'inverse, une très légère augmentation est observable pour les pics d'août et de décembre. A noter une forte augmentation de l'écart-type en juillet.




Figure 6 – Analyse de l'écart-type par mois et par horizon

Le découpage par horizon et par mois permet également d'en savoir davantage sur les distributions respectives de la température moyenne.

```
# 4/ Investigating the data distribution for each horizon (mean, max, min, sd)
temperature_monthly_h1 = setNames(
  do.call(data.frame,
    aggregate(temperature_h1$temperature_H1 ~ temperature_h1$Mois,
      data=temperature_h1,
      function(x) c(Mean = mean(x), Max = max(x), Min = min(x), SD = sd(x)))),
  c('month', 'temperature_avg', 'temperature_max', 'temperature_min', 'temperature_sd'))
temperature_monthly_h2 = setNames(
  do.call(data.frame,
    aggregate(temperature_h2$temperature_H2 ~ temperature_h2$Mois,
      data=temperature_h2,
      function(x) c(Mean = mean(x), Max = max(x), Min = min(x), SD = sd(x)))),
  c('month', 'temperature_avg', 'temperature_max', 'temperature_min', 'temperature_sd'))
temperature_monthly_h3 = setNames(
  do.call(data.frame,
    aggregate(temperature_h3$temperature_H3 ~ temperature_h3$Mois,
      data=temperature_h3,
      function(x) c(Mean = mean(x), Max = max(x), Min = min(x), SD = sd(x)))),
  c('month', 'temperature_avg', 'temperature_max', 'temperature_min', 'temperature_sd'))
```

La différence entre les moyennes mensuelles des températures entre les horizons ayant la plus grande étendue (H3-H1) indique une hausse globale très marquée pour certains mois (février, juillet en particulier).

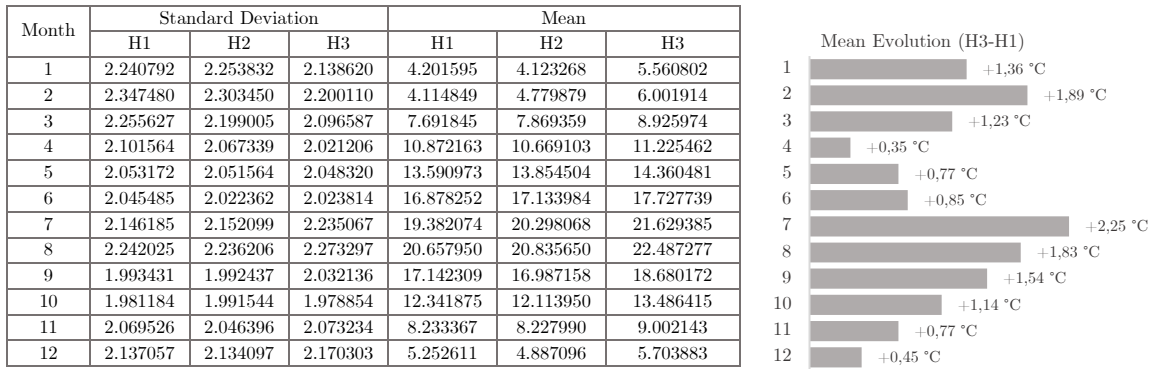


Figure 7 – Analyse de la distribution des valeurs de température moyenne par mois et par horizon

D. Analyse de l'autocorrélation spatiale

Pour fiabiliser l'interpolation de données, la présence d'autocorrélation spatiale doit être vérifiée. Pour rappel, l'autocorrélation mesure la corrélation d'une variable avec elle-même, lorsque les observations sont considérées avec un décalage dans le temps (autocorrélation temporelle) ou dans l'espace (autocorrélation spatiale). Cette mesure est donc définie comme la corrélation, positive ou négative, d'une variable avec elle-même du fait de la localisation spatiale des observations. L'analyse de l'autocorrélation spatiale permet notamment une analyse quantifiée de la structure spatiale de la température moyenne globale.

Empiriquement, ce phénomène peut être identifié par intuition. En effet, l'autocorrélation est positive lorsque des valeurs de température similaires se regroupent géographiquement. A l'inverse, il existe également une corrélation négative lorsque des valeurs de température dissemblables se regroupent géographiquement. En d'autres termes, des lieux proches sont plus différents que des lieux éloignés. Bien que ce scénario existe, il est peu probable de l'observer sur des températures qui sont la plupart du temps corrélées au voisinage.

Des méthodes plus robustes permettent d'affirmer avec précision la présence d'autocorrélation spatiale dans les données de température. L'une d'entre elles, l'indice de Moran (ou I de Moran), sera celle utilisée dans le cadre de cette étude. Un test doit être réalisé afin de démontrer la présence ou non de ce phénomène. Pour rappel, l'hypothèse nulle du test de Moran indique une absence d'autocorrélation sur la variable observée. Elle suppose que l'attribut analysé est distribué aléatoirement parmi les entités de la zone d'étude. Autrement dit, les processus spatiaux qui favorisent le modèle observé de valeurs sont aléatoires. Si la p-valeur calculée est inférieure à 0.05, alors l'hypothèse nulle est rejetée, démontrant ainsi la présence d'autocorrélation.

Pour ce faire, un découpage du jeu de données par mois et par horizon a été nécessaire afin de palier au temps de calcul important engendré. Seuls les mois de février et d'août ont ainsi été sélectionnés comme base de référence du fait de leur variance atypique.

```
## C. Looking for a spatial autocorrelation on the data using Moran's i
# 1/ Grouping temperatures per month by joining on horizons ("NORTAV_H1", "NORTAV_H2", "NORTAV_H3")
temperature_h1 = subset(temperature_means_df[temperature_means_df$Integration == "H1",],
  select=(-c(Contexte,Integration,Point,NORTXAV,NORTNAV)))
colnames(temperature_h1)[4] = 'temperature_H1'
temperature_h2 = subset(temperature_means_df[temperature_means_df$Integration == "H2",],
  select=(-c(Contexte,Integration,Point,NORTXAV,NORTNAV)))
colnames(temperature_h2)[4] = 'temperature_H2'
temperature_h3 = subset(temperature_means_df[temperature_means_df$Integration == "H3",],
  select=(-c(Contexte,Integration,Point,NORTXAV,NORTNAV)))
colnames(temperature_h3)[4] = 'temperature_H3'
head(temperature_h3)

# 2/ Subsetting data sets per month and horizon
temperature_h1_febbruary = setNames(temperature_h1[temperature_h1$Mois == 2,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
temperature_h2_febbruary = setNames(temperature_h2[temperature_h2$Mois == 2,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
temperature_h3_febbruary = setNames(temperature_h3[temperature_h3$Mois == 2,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
temperature_h1_august = setNames(temperature_h1[temperature_h1$Mois == 8,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
temperature_h2_august = setNames(temperature_h2[temperature_h2$Mois == 8,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
temperature_h3_august = setNames(temperature_h3[temperature_h3$Mois == 8,],
  c('Latitude', 'Longitude', 'Month', 'Temperature'))
```


Une fois les données exploitables, le test de Moran peut alors avoir lieu par l'intermédiaire d'une fonction dédiée, construite pour l'occasion.

```
# 3/ Building a function to perform moran's i test
moran_i_test = function(dataset_sample, temperature_variable)
{
  temperatures_distances_inv = 1/as.matrix(dist(cbind(dataset_sample$Longitude, dataset_sample$Latitude)))
  diag(temperatures_distances_inv) = 0
  Moran.I(temperature_variable, temperatures_distances_inv)
}

# 4/ Performing the Moran's I to check spatial autocorrelation
# Notes: if p-value inferior to 0.05, the hypothesis of autocorrelation is validated
moran_test_h1_february = moran_i_test(temperature_h1_february, temperature_h1_february$Temperature)
moran_test_h2_february = moran_i_test(temperature_h2_february, temperature_h2_february$Temperature)
moran_test_h3_february = moran_i_test(temperature_h3_february, temperature_h3_february$Temperature)
moran_test_h1_august = moran_i_test(temperature_h1_august, temperature_h1_august$Temperature)
moran_test_h2_august = moran_i_test(temperature_h2_august, temperature_h2_august$Temperature)
moran_test_h3_august = moran_i_test(temperature_h3_august, temperature_h3_august$Temperature)

# 5/ Building a confusion matrix based on moran's i tests
data.frame(Horizon=c('H1', 'H2', 'H3', 'H1', 'H2', 'H3'),
           Month=c('February', 'February', 'February', 'August', 'August', 'August'),
           Moran_p_value=c(moran_test_h1_february$p.value, moran_test_h2_february$p.value, moran_test_h3_february$p.value,
                           moran_test_h1_august$p.value, moran_test_h2_august$p.value, moran_test_h3_august$p.value))
```

La construction d'une matrice de confusion, regroupant chacune des p-valeurs pour les six jeux de données, est créée afin de rejeter ou non l'hypothèse nulle.

Les résultats obtenus confirment la présence d'autocorrélation avec des p-value inférieures à 0.05 pour l'ensemble des segments.

| Horizon | Month | Observed | Expected | sd | p-value |
|---------|----------|-----------|---------------|--------------|---------|
| H1 | February | 0.2188663 | -0.0001162656 | 0.0002331163 | 0 |
| H2 | February | 0.218258 | -0.0001162656 | 0.0002331163 | 0 |
| H3 | February | 0.2012971 | -0.0001162656 | 0.0002331002 | 0 |
| H1 | August | 0.1470205 | -0.0001162656 | 0.0002331023 | 0 |
| H2 | August | 0.1510809 | -0.0001162656 | 0.0002331089 | 0 |
| H3 | August | 0.142823 | -0.0001162656 | 0.0002330935 | 0 |

Figure 8 – Résultats d'analyse du test de Moran

Par généralisation de cette mesure sur l'ensemble des données de température étudiées, l'hypothèse nulle peut donc être rejetée et la présence d'autocorrélation confirmée. L'interpolation spatiale des valeurs est désormais pleinement possible.

III. Analyse variographique de la température

A. Choix de la méthode d'estimation linéaire

Dans cette étude, l'interpolation spatiale sera effectuée par krigeage ordinaire, méthode d'estimation linéaire permettant de minimiser la variance. Pour rappel, le krigeage réalisera l'interpolation spatiale de la température moyenne par calcul de l'espérance mathématique d'une variable aléatoire, utilisant l'interprétation et la modélisation du variogramme expérimental, estimateur du variogramme théorique. Cet estimateur linéaire est sans biais et tient compte non seulement de la distance entre les données et le point d'estimation, mais également des distances entre les données deux à deux.

B. Calcul et ajustement de la fonction aléatoire intrinsèque

Afin de procéder au krigeage ordinaire, il est donc nécessaire de procéder à une analyse variographique de la température grâce à l'étude du variogramme expérimental associé aux valeurs. Pour ce faire, une fonction spécifique est créée permettant de calculer puis d'ajuster le variogramme.

```
### II. Building an experimental variogram fitting the data sample
## A. Building a function to fit variogram parameters of the best selected model to the associated sample variogram
options(warn = -1) # Removing potential recurrent warnings
show.vgms()
plot_exp_variogram = function(data, model) {
  coordinates(data) = ~ Longitude + Latitude
  variogram_model = vgm(c(model))
  variogram_sample = variogram(object=data$Temperature~1,
                              location=coordinates(data),
                              data=data)

  variogram_fitted = fit.variogram(variogram_sample, model=variogram_model, fit.kappa = TRUE)
  preds = variogramLine(variogram_fitted, maxdist=max(variogram_sample$dist), col=2, lwd=2)
  print(paste0('The sum of squares errors is minimized for the ',
              variogram_fitted[2,1], ' model and is equal to ',
              round(attr(variogram_fitted, 'SSErr'), digits=2)))
  title = paste0('Experimental variogram based on ', variogram_fitted[2,1], ' model')
  ggplot(variogram_sample, aes(x=dist, y=gamma)) +
    geom_point(size=2) + labs(title=title, x='Distance', y='Gamma', text=element_text(family='LM Roman 10', size=14)) +
    geom_line(data=preds, aes(x=dist, y=gamma, color=variogram_fitted[2,1]), size=2) +
    scale_color_manual(name = 'Models', values='#E69F00') +
    theme(legend.position='top', text=element_text(family='LM Roman 10', size=10))
}
```

L'ajustement est réalisé grâce à la sélection du meilleur modèle à employer. En effet, la fonction teste l'ensemble des modèles disponibles depuis la librairie 'gstat' via la commande `show.vgms()`, puis affiche le modèle qui minimise la somme des carrés des erreurs.

```
## B. Running the previous function & selecting the model that minimizes the Sum of Squares errors
# Notes: here, all the available models are selected since the package tests all models by configured it that way
plot_exp_variogram(data=temperature_h1_february,
  model=c('Sph','Nug','Exp','Gau','Exc','Mat','Cir','Lin','Bes',
    'Pen','Per','Wav','Hol','Log','Pow','Spl','Leg','Err'))
# Conclusion: the Matérn model seems the most appropriate for February in horizon 1 with a SSE equal to 361904.19
plot_exp_variogram(data=temperature_h1_august,
  model=c('Sph','Nug','Exp','Gau','Exc','Mat','Cir','Lin','Bes',
    'Pen','Per','Wav','Hol','Log','Pow','Spl','Leg','Err'))
# Conclusion: the Matérn model seems the most appropriate for August in horizon 1 with a SSE equal to 291215.66
plot_exp_variogram(data=temperature_h3_february,
  model=c('Sph','Nug','Exp','Gau','Exc','Mat','Cir','Lin','Bes',
    'Pen','Per','Wav','Hol','Log','Pow','Spl','Leg','Err'))
# Conclusion: the Matérn model seems the most appropriate for February in horizon 3 with a SSE equal to 275552.43
plot_exp_variogram(data=temperature_h3_august,
  model=c('Sph','Nug','Exp','Gau','Exc','Mat','Cir','Lin','Bes',
    'Pen','Per','Wav','Hol','Log','Pow','Spl','Leg','Err'))
# Conclusion: the Matérn model seems the most appropriate for August in horizon 3 with a SSE equal to 279032.29
```

Pour prendre un exemple, la synthèse comparative de l'ajustement des modèles sur les données d'août pour l'horizon lointain peut être détaillée comme suit :

| Model | Nugget Partial Sill | Model Partial Sill | Model Range | Model Kappa | Model SSErr | Rank |
|--------------------------|---------------------|--------------------|-------------|-------------|-------------|------|
| Matern | 0.3193149 | 4.403017 | 0.758845 | 0.8 | 279032.3 | 1 |
| Bessel | 0.455631 | 4.221225 | 0.6555939 | - | 279911.4 | 2 |
| Exponential | 0.00000 | 4.906235 | 1.115602 | - | 303983.5 | 3 |
| Pentaspheical | 0.2269682 | 4.2615635 | 2.69411 | - | 327636 | 4 |
| Spherical | 0.2671984 | 4.1937122 | 2.214909 | - | 342084.6 | 5 |
| Circular | 0.3147383 | 4.1303014 | 1.949301 | - | 363665.3 | 6 |
| Gaussian | 0.7849956 | 3.6110154 | 1.013421 | - | 410013 | 7 |
| Linear | 0.47058 | 3.992991 | 1.742995 | - | 485403.5 | 8 |
| Wave | 0.9062056 | 3.1329558 | 1.386272 | - | 1027695 | 9 |
| Exponential class/stable | 0.00000 | 39.42215 | 209.1833 | 0.5 | 1492985 | 10 |
| Power | 0.00000 | 2.587007 | 0.5052207 | - | 1520090 | 11 |
| Logarithmic | 1.880684 | 4.009573 | 0.5608699 | - | 16749171 | 12 |
| Periodic | 2.436566 | 0.00000 | 1.84938 | - | 19294650 | 13 |
| Hole | 1.59446091 | 0.08194152 | 6.208967 | - | 26263946 | 14 |
| Spline | 1.935301 | 5.163613 | 1.84938 | - | 40515043 | 15 |
| Measurement Error | 1.935301 | 5.163613 | 0.00000 | - | 237822901 | 16 |
| Legendre | 1.935301 | 5.163613 | 1.84938 | - | 7414579580 | 17 |

Figure 9 – Synthèse des résultats pour l'ajustement du variogramme sur les données d'août à horizon 3

Il semble que cela soit le modèle Matérn qui permette d'ajuster au mieux les valeurs, quel que soit le jeu de données étudié. Les sommes des carrés des erreurs minimales obtenues sont les suivantes :

| Sum of squared errors | Horizon 1 | Horizon 3 |
|-----------------------|-----------|-----------|
| February | 361904.19 | 275552.43 |
| August | 291215.66 | 279032.29 |

Figure 10 – Somme des carrés des erreurs du variogramme ajusté via le modèle Matérn

Enfin, la fonction affiche le diagramme du variogramme expérimental construit à partir des données initiales et du modèle préalablement sélectionné. Il peut toutefois être intéressant d'investiguer davantage en analysant visuellement les possibles diagrammes obtenus afin de se faire une idée de l'ajustement réalisé par le variogramme expérimental.

C. Analyse visuelle des diagrammes associés aux variogrammes expérimentaux

En tenant compte des résultats d'analyse obtenus de la synthèse comparative des différents modèles testés sur les données pour août à l'horizon lointain, il semble que le modèle Bessel soit également performant bien que non-optimal.

```
## C. Investigating visually on the two best models and picking the one to use for the rest of the study
# Note: for reading simplicity, only February H1 has been detailed below:
# 1/ Build the variogram sample based on temperatures for February & August in horizon 3
coordinates(temperature_h1_february) = ~ Longitude + Latitude # Identifying coordinates in the data set
variogram_temperature_h1_february = variogram(object=temperature_h1_february$Temperature~1,
  location=coordinates(temperature_h1_february),
  data=temperature_h1_february)
# 2/ Fitting variograms for February H1 using Matérn & Bessel models
variogram_fitted_temperature_h1_february_bessel = fit.variogram(variogram_temperature_h1_february,
  model=vgm(model='Bes', range=1))
variogram_fitted_temperature_h1_february_matern = fit.variogram(variogram_temperature_h1_february,
  model=vgm(model='Mat', range=1))
```

Il pourrait être intéressant de comparer leur diagramme respectif afin de visualiser les ajustements effectués.

```
# 3/ Plotting both experimental variograms
# a) For February at horizon 1
ggplot(variogram_temperature_h1_february, aes(x=dist, y=gamma)) + geom_point(size=2) +
  labs(title='Experimental variogram based on Matérn & Bessel models for February H1', x='Distance', y='Gamma',
        text=element_text(family='LM Roman 10', size=10)) +
  geom_line(data=variogramLine(variogram_fitted_temperature_h1_february_bessel,
                                maxdist=max(variogram_temperature_h1_february$dist)),
            aes(x=dist, y=gamma, color='Bessel'),
            size=2) +
  geom_line(data=variogramLine(variogram_fitted_temperature_h1_february_matern,
                                maxdist=max(variogram_temperature_h1_february$dist)),
            aes(x=dist, y=gamma, color='Matérn'),
            size=2) +
  scale_color_manual(name = 'Models', values=c('Bessel'='#E69F00', 'Matérn'='#56B4E9')) +
  theme(legend.position='top', text=element_text(family='LM Roman 10', size=10))
# Conclusion: the model Matérn seems also visually the best one for February
```

Les diagrammes des variogrammes empiriques obtenus pour l'horizon proche sont les suivants :

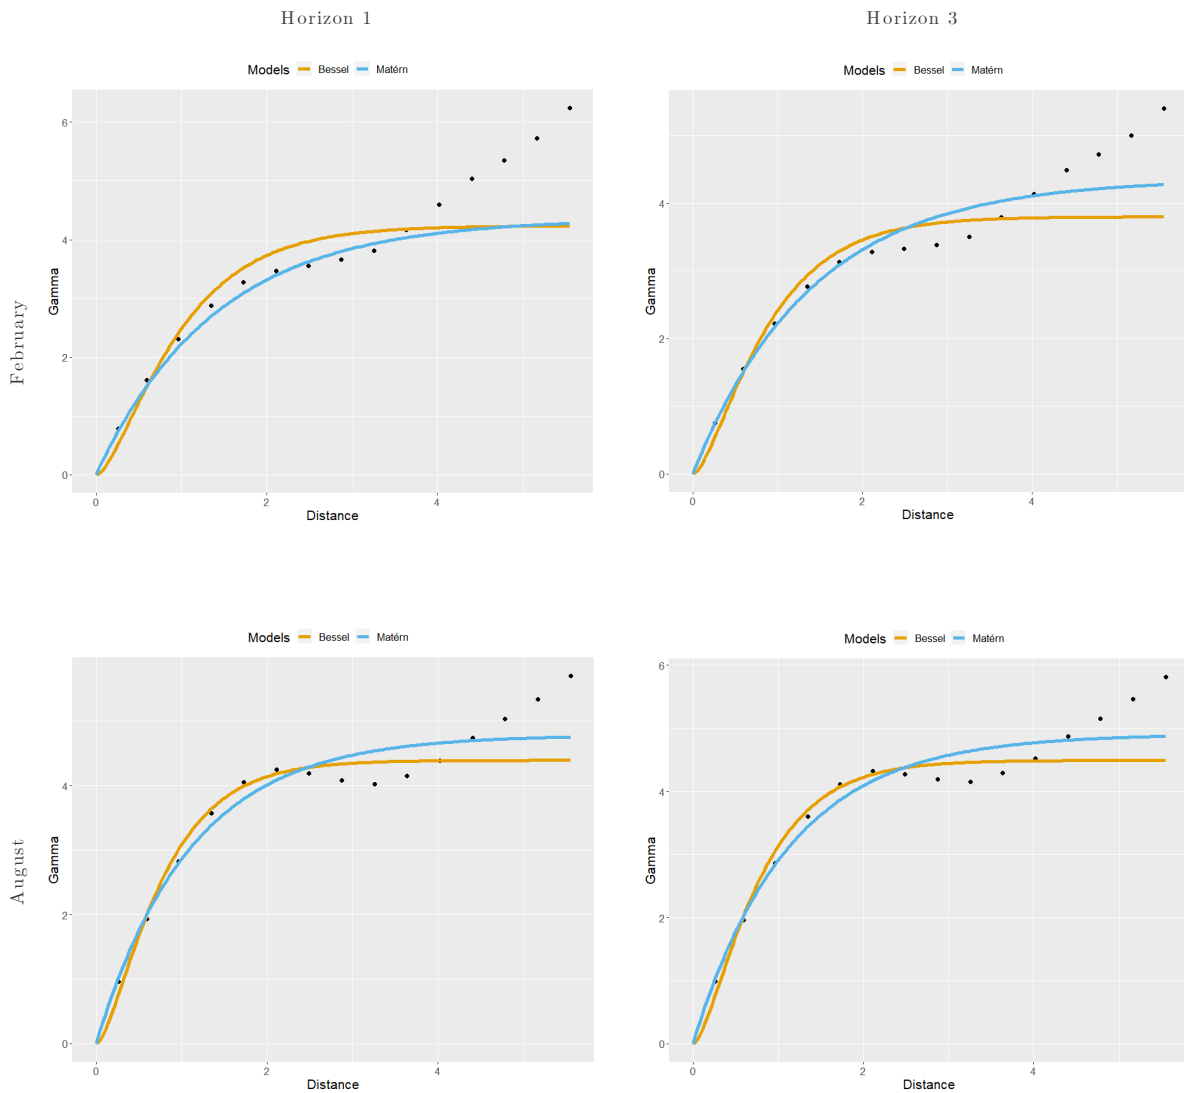


Figure 11 – Visualisation des diagrammes associés aux variogrammes empiriques et théoriques

Il semble que le variogramme théorique (en couleur) s'ajuste mieux au variogramme empirique (en pointillé) pour le mois d'août. Dans tous les cas, le modèle Matérn semble être le plus recommandé. Aussi, l'observation des diagrammes corrobore les résultats obtenus précédemment via les fonctions compilées depuis la librairie 'gstat'.

D. Création d'une grille de projection

Le calcul et l'ajustement de la fonction aléatoire intrinsèque est la première étape du krigeage. La seconde consiste à construire un nouvel objet spatial sur lequel la prévision estimée par krigeage pourra être projetée.

Cet objet, appelé communément « grille », définit le cadre de projection sur lequel la nouvelle donnée sera estimée.

```
### III. Performing an ordinary kriging based on variogram model of the temperature
## A. Building France as a spatial object to use it then as prediction locations
# 1/ Importing France map as SpatialPolygon object
france_map = getData(country = 'FRA', level = 0)
# 2/ Creating a rectangular grid over it
france_grid = makegrid(france_map, n = 100000)
colnames(france_grid) = c('x', 'y')
# 3/ Converting the grid into spatial points and subsetting these points by the polygons
france_spatial_points = SpatialPoints(coords=france_grid, proj4string=CRS(proj4string(france_map)))
# 4/ Subsetting all points in France's spatial points that fall within France map
france_spatial_points_in = france_spatial_points[france_map, ]
# 5/ Visualizing the prediction locations which can be used for kriging
plot(france_map = ggplot(as.data.frame(coordinates(france_spatial_points_in)), aes(x1, x2)) +
     geom_point(aes(x, y), size=0.5) + coord_equal() + xlim(-6,10) + ylim(41,52))
```

Puisque l'étude porte sur les températures moyennes globales enregistrées en France métropolitaine, la grille associée au krigeage devra donc dessiner les contours de la métropole.

Une carte de la France métropolitaine est ainsi construite grâce aux bibliothèques 'raster' et 'sp', permettant ainsi d'avoir une espace de projection précis.




Figure 12 – Grille de projection de la France métropolitaine

E. Estimation des prévisions par krigeage ordinaire

Avant de procéder à l'interpolation spatiale des données, chacun des quatre segments doit d'abord être configuré. Il faut notamment s'assurer de l'harmonisation du système de coordonnées de référence¹⁰ ainsi que de l'identification des coordonnées pour chaque segment étudié.

```
## B. Performing an ordinary kriging
# Note: for reading simplicity, only February H1 has been detailed below:
# 1/ Reshaping the initial data set
temperature_h1_february = subset(setNames(temperature_h1[temperature_h3$Mois == 2,],
                                           c('Latitude', 'Longitude', 'Month', 'Temperature')), select=-c(Month))
coordinates(temperature_h1_february) = ~ Longitude + Latitude

# 2/ Matching data set CRS with the right parameters
proj4string(temperature_h1_february) = CRS('+proj=longlat +datum=WGS84 +no_defs')

# 3/ Creating a prediction surface map with kriging
# Notes: 'varl.pred' stands for the predicted values of the variable and 'varl.var' for the variance of the predictions
krigeage_h1_february = krige(formula=Temperature~1, # '~1' standing for 'depending on mean'
                             locations=temperature_h1_february,
                             newdata=france_spatial_points_in,
                             model=variogram_fitted(temperature_h1_february_matern))
krigeage_h1_february_df = setNames(as.data.frame(krigeage_h1_february),
                                   c('Longitude', 'Latitude', 'Temperature', 'Variance'))
head(krigeage_h1_february_df)
```

L'estimation des prévisions des températures moyennes par la méthode du krigeage ordinaire peut enfin avoir lieu par l'intermédiaire de la bibliothèque 'gstat' et la fonction krige() associée.

L'affichage des premières observations permet d'identifier les prévisions de températures estimées (varl.pred par défaut) ainsi que la variance associée (varl.var par défaut).

| Longitude | Latitude | Temperature | Variance |
|-----------|----------|-------------|----------|
| 9.136 | 41.400 | 5.794152 | 4.612915 |
| 9.190 | 41.400 | 5.154799 | 4.870485 |
| 9.082 | 41.454 | 4.851046 | 4.967714 |
| 9.136 | 41.454 | 4.975961 | 4.967340 |

Figure 13 – Prévisions de température estimées par krigeage

¹⁰ L'acronyme « CRS » pour Coordinate Reference System correspond à l'appellation d'usage.

F. Comparaison annuelle des températures moyennes

Une fois l'interpolation des valeurs effectuée, il est possible d'afficher les nouvelles estimations de température sous la forme de cartes de surface de prévision.

```
## C. Comparing temperature predictions over horizons
# Note: for reading simplicity, only horizon 1 has been detailed below
# 1/ Plotting temperature predictions for horizon 1 (2021-2050)
plot_temperature_february_h1 = ggplot(data=krigeage_h1_february_df, aes(x=Longitude, y=Latitude)) +
  c(geom_tile(data=krigeage_h1_february_df, aes(fill=Temperature))) +
  #scale_fill_gradient(high = '#e60000', low = '#0064e6') +
  scale_fill_gradientn(colors = topo.colors(20),
    #trans = "log10",
    limits = c(0,10),
    breaks = c(0,2,4,6,8,10)) + coord_equal() +
  ggtitle('Global average temperatures for February in H1 (2021-2050)') +
  theme(legend.position='top', text=element_text(family='LM Roman 10', size=10))
summary(krigeage_h1_february_df)
plot_temperature_august_h1 = ggplot(data=krigeage_h1_august_df, aes(x=Longitude, y=Latitude)) +
  c(geom_tile(data=krigeage_h1_august_df, aes(fill=Temperature))) +
  #scale_fill_gradient(high = '#e60000', low = '#0064e6') +
  scale_fill_gradientn(colors = topo.colors(20),
    #trans = "log10",
    limits = c(16,26),
    breaks = c(16,18,20,22,24,26)) + coord_equal() +
  ggtitle('Global average temperatures for August in H1 (2021-2050)') +
  theme(legend.position='top', text=element_text(family='LM Roman 10', size=10))
summary(krigeage_h1_august_df)
```

Ce travail de visualisation permet de comparer la carte des températures moyennes en France métropolitaine à des horizons et des mois différents.

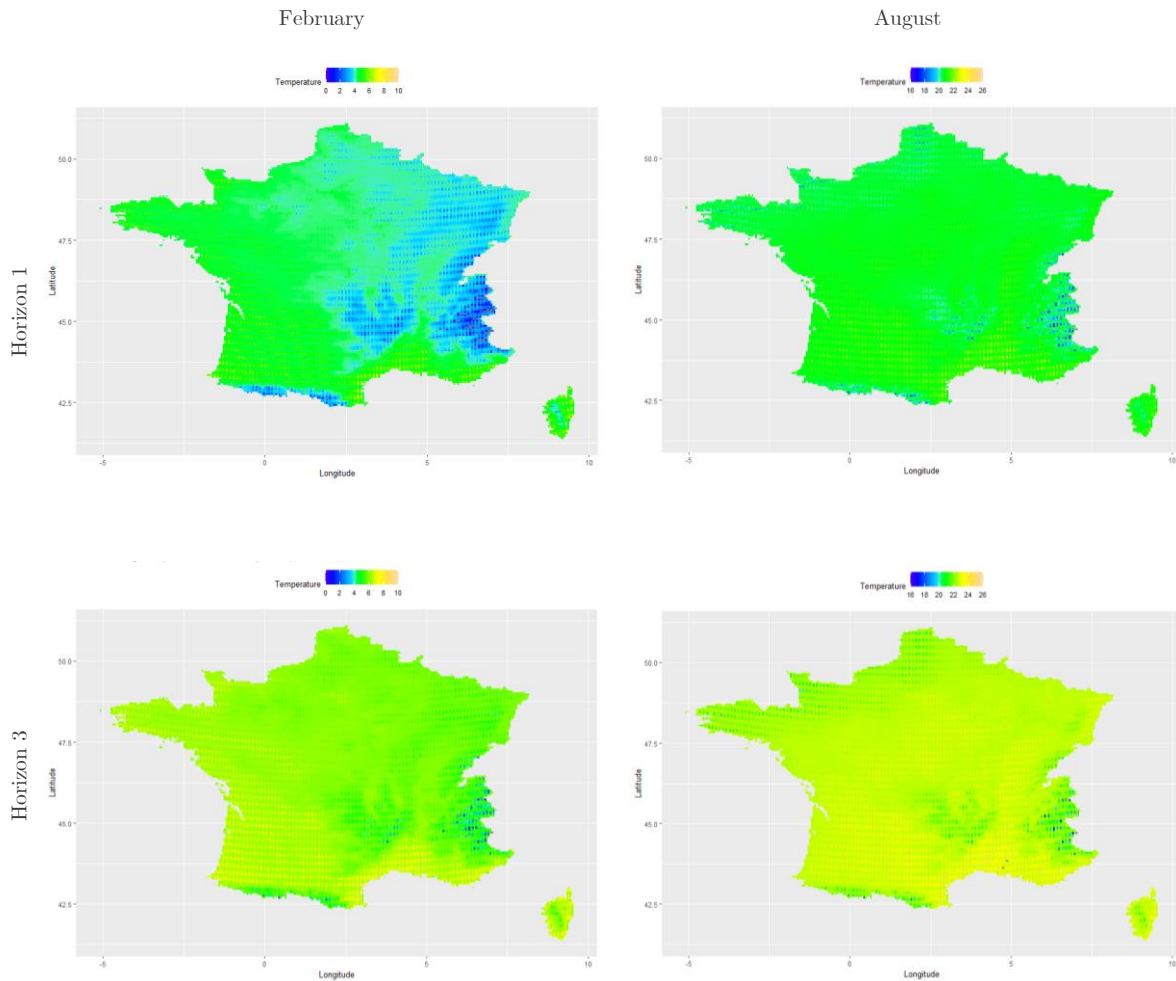


Figure 14 – Carte de la France métropolitaine aux mois de février et août et aux horizon 1 et 3

Il est aisé de constater l'importante hausse des températures moyennes entre les deux horizons observés.

Pour février, les régions montagneuses (Alpes, Massif central, Juras et Pyrénées) font partie des zones les plus froides à l'horizon le plus proche (2021-2050) avec des températures plafonnant autour de 4°C.

Ce n'est toutefois plus le cas à l'horizon le plus éloigné (2071-2100) où ces dernières dépassent ce seuil de un à deux degrés. C'est ainsi que la couleur bleue (<4°C) disparaît presque totalement de la carte et de nouvelles étendues jaunes (>7°C) apparaissent sur le pourtour méditerranéen. Ce phénomène de réchauffement est également visible pour août avec une carte de la France métropolitaine qui passe du vert (~21°C) au jaune (~23°C) sur presque tout le territoire.

Il est important de rappeler qu'une telle augmentation de la température moyenne aurait des conséquences désastreuses sur le vivant : risques sanitaires accrus, extinction d'espèces végétales et animales, augmentation du nombre de désastres naturels, hausse du niveau des océans.

En outre, la température moyenne n'est qu'une composante de ce dérèglement et l'étude d'indices complémentaires serait à entreprendre afin d'apporter davantage de précision dans le diagnostic.

IV. Etude complémentaire de la température moyenne entre 2021 et 2022

Pour étayer ce travail d'analyse de l'évolution de la température moyenne, les années 2021 et 2022 peuvent aussi être étudiées pour les mois de février et août afin de se faire une idée plus concrète de ces changements. Pour ce faire, de nouveaux jeux de données ont été téléchargés depuis la plateforme [meteociel.fr](https://www.meteociel.fr)¹¹, puis ont été prétraités et formatés en amont via Excel.

Une fois ce travail réalisé, une interpolation spatiale des données par krigeage ordinaire est effectuée en suivant la procédure précédemment détaillée.

```
## D. Plotting temperature predictions for August 2022
# 1/ Importing the temperatures for August 2022
# Note 1: data were downloaded from meteociel.fr and reshaped in Excel beforehand (https://www.meteociel.fr/climatologie/)
# Note 2: for reading simplicity, only February 2021 has been detailed below
temperature_2021_2022 = read.table(file='20220914_temperatures_moyennes_france_2021_2022.csv', sep=';',
                                   dec=',', header=TRUE, skipNul=TRUE, encoding='UTF-8')
temperature_2021_fbruary = subset(setNames(temperature_2021_2022[temperature_2021_2022$month == '2021/02',],
                                           c('City', 'Month', 'Longitude', 'Latitude', 'Temperature')),
                                  select=-c(City, Month))

head(temperature_2021_fbruary)
summary(temperature_2021_fbruary)
# 2/ Running the created function to fit variogram and select the best model that minimizes the Sum of Squares errors
plot_exp_variogram_febbruary_2021 = plot_exp_variogram(data=temperature_2021_fbruary,
                                                        model=c('Sph', 'Nug', 'Exp', 'Gau', 'Exc', 'Mat', 'Cir', 'Lin', 'Bes',
                                                                'Pen', 'Per', 'Wav', 'Hol', 'Log', 'Pow', 'Spl', 'Leg', 'Err'))

# Conclusion for February 2021: The sum of squares errors is minimized for the 'Power' model and is equal to 186.26

# 3/ Fitting to the sample variogram
options(warn = -1)
coordinates(temperature_2021_fbruary) = ~ Longitude + Latitude ;
proj4string(temperature_2021_fbruary) = CRS('+proj=longlat +datum=WGS84 +no_defs')
variogram_2021_fbruary = fit.variogram(variogram(object=temperature_2021_fbruary$Temperature~1,
                                                  location=coordinates(temperature_2021_fbruary),
                                                  data=temperature_2021_fbruary),
                                       model=vgm(model='Pow', range=1))

# 4/ Performing an ordinary kriging for both months
krigeage_2021_fbruary = krige(formula=Temperature~1,
                              locations=temperature_2021_fbruary,
                              newdata=france_spatial_points_in,
                              model=variogram_2021_fbruary)

# 5/ Plotting France map with the interpolated data for February & August 2022
krigeage_2021_fbruary_df = setNames(as.data.frame(krigeage_2021_fbruary),
                                     c('Longitude', 'Latitude', 'Temperature', 'Variance'))
summary(krigeage_2021_fbruary_df)
plot_temperature_febbruary_2021 = ggplot(data=krigeage_2021_fbruary_df, aes(x=Longitude, y=Latitude)) +
  c(geom_tile(data=krigeage_2021_fbruary_df, aes(fill=Temperature))) +
  scale_fill_gradientn(colors = topo.colors(20),
                      limits = c(0,15),
                      breaks = c(0,3,6,9,12,15)) + coord_equal() +
  ggtitle('Global average temperatures for February 2021') +
  theme(legend.position='top', text=element_text(family='LM Roman 10', size=10))
summary(krigeage_2021_fbruary_df)
```

¹¹ Les coordonnées GPS (degrés décimaux) ont été prétraitées manuellement via Excel à partir des données [meteociel.fr](https://www.meteociel.fr), téléchargeable depuis le lien suivant : shorturl.at/aKO07

Bien que la méthode d'étalonnage et de recalcul ne soit probablement pas la même que pour le premier jeu de données, et donc que la comparaison des niveaux de température ne soit pas complètement possible, il est intéressant de constater une hausse exceptionnelle des températures moyennes pour août 2022 par rapport à l'année passée. A noter que le mois de février fut plus doux en 2022 par rapport à 2021.

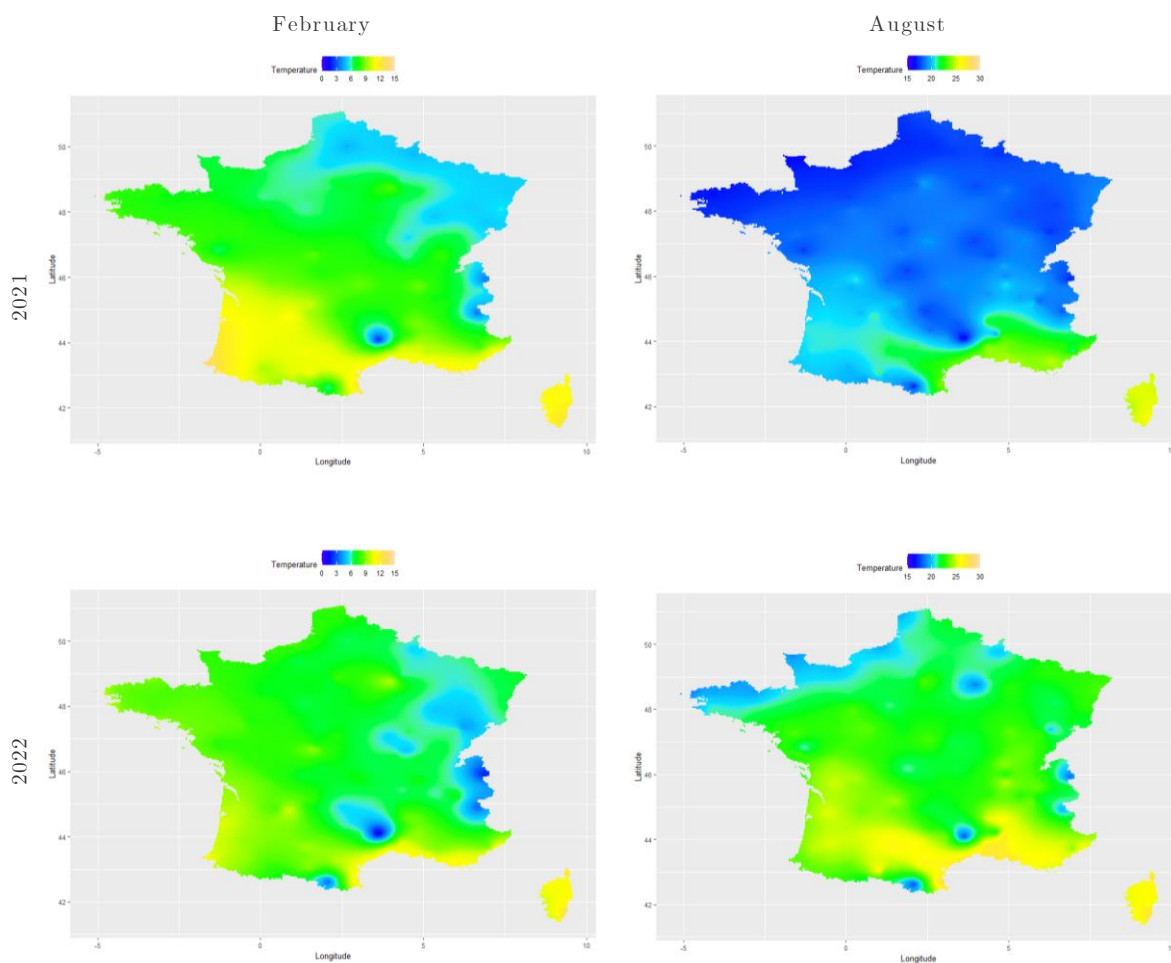


Figure 15 – Evolution de la carte de la France métropolitaine entre 2021 et 2022 aux mois de février et août